

Predicción del precio de criptomonedas por medio del modelo VAR y el modelo LSTM

Andrés David Nivia Vega, Martín Camilo Rodríguez Murcia

23 de enero de 2026

1. Resumen

La predicción de los valores futuros de las criptomonedas es un campo que ha captado cada vez más interés tanto en el campo académico como en el práctico, producto del auge que han tenido estos activos en los distintos mercados a nivel mundial. Sin embargo, similar a los activos financieros, estas series de tiempo han demostrado ser sumamente difíciles de modelar debido a lo caótico de su mercado, que deriva en una altísima volatilidad y en un comportamiento inesperado. Estas características han sido especialmente problemáticas al momento de utilizar algunos de los modelos econométricos tradicionales como los ARIMA. Es por ello que desde el machine learning han surgido iniciativas para predecir el comportamiento de estas series por medio de redes neuronales recurrentes, y particularmente por medio de modelos como el LSTM, los cuales han demostrado ser más capaces que los modelos ARIMA para modelar criptomonedas.

Sin embargo existen otros modelos econométricos para tratar series de tiempo como lo es el VAR, el cual puede contar con más recursos que los modelos ARIMA. Es por ello que este trabajo se centra en responder la pregunta de si modelos de machine learning, más específicamente el LSTM, son mejores que el modelo VAR para predecir el precio la criptomoneda más relevante a nivel mundial: Bitcoin. Los resultados indican que el modelo VAR sigue siendo fuertemente restringido por los supuestos de los que parte, y si bien demuestra mayores bondades para predecir el precio de Bitcoin en un periodo de poca volatilidad, en general y en el largo plazo presenta predicciones considerablemente más desacertadas que las obtenidas por medio del modelo LSTM.

Palabras Clave: Criptomonedas, predicción, modelos econométricos, machine learning, VAR, LSTM.

2. Introducción

El mercado de activos financieros ha sido constantemente uno de los más atractivos a nivel mundial. Esto se debe, por un lado, a las grandes ganancias que puede otorgar a pequeños agentes particulares, y por el otro, al financiamiento que brinda a grandes empresas. De este mercado financiero se deriva uno que ha venido ganando cada vez más fuerza y se ha posicionado como el nuevo boom en materia de inversión: el mercado de criptoactivos o, como mejor se les conoce, criptomonedas.

Si bien no son consideradas activos financieros en si, al no estar respaldadas por ningún bien físico, se han popularizado en todo el mundo y son altamente demandadas por inversores experimentados y principiantes. La razón de esto radica principalmente en la carencia de regulación formal en este mercado, lo cual facilita la entrada a casi cualquier persona. Si a ello se le suma la gran valorización que han tenido las criptomonedas en ciertos periodos, alcanzando tasas de crecimiento superiores a 200 % en un solo trimestre (Barlin, 2017), no es difícil entender la fuente de su atractivo.

De esta forma, con el ascenso de las criptomonedas, también hay un creciente interés por parte de los distintos agentes del mercado por predecir sus valores futuros. Sin embargo, esta ha probado ser una tarea sumamente complicada para los métodos econométricos tradicionales como los ARIMA (autoregressive integrated moving average), debido a las características propias de estos activos. Las series de tiempo de las criptomonedas en general cuentan con muchas de las características problemáticas de los activos financieros tradicionales, con los cuales también es difícil trabajar con modelos econométricos (Catania et al., 2018). En pocas palabras, los mercados de activos financieros y de criptomonedas son muy caóticos e impredecibles, lo cual se traduce en series de tiempo con altísima volatilidad, no linealidad y no estacionariedad, características que violan supuestos necesarios

en muchos modelos econométricos (Paiva et al., 2019).

Por supuesto, ante estas limitaciones de modelos como los ARIMA, han surgido otros modelos econométricos, como lo son los de la familia GARCH (generalized autoregressive conditional heteroscedasticity), que tratan justamente de modelar adecuadamente la alta volatilidad de esta clase de series de tiempo. Sin embargo, también han surgido otras iniciativas desde otros campos, particularmente desde el machine learning (ML). Así, se han utilizado distintos modelos de ML basados en algoritmos genéticos, lógica difusa, support vector machine o redes neuronales (Paiva et al., 2019). Estos últimos modelos en particular han demostrado ser más aptos que los ARIMA para la predicción de series de tiempo financieras (Siami-Namini & Namin, 2018), principalmente debido a que estos modelos no son tan rigurosos en cuanto a supuestos que deban cumplir los datos, sino que, por el contrario, se van adaptando según las características de los mismos.

Con base en lo anterior, lo que se buscará en este artículo es comprobar de primera mano si efectivamente hay modelos de machine learning con la capacidad de predecir con mayor precisión los valores futuros de las criptomonedas, comparados con los modelos econométricos tradicionales. En particular, se compararán las predicciones para Bitcoin, la criptomoneda más popular, de dos modelos: uno econométrico y otro de ML. El modelo econométrico que se usará es el VAR (vector autoregression), que, si bien cuenta con muchas de las restricciones de los modelos ARIMA, permite la inclusión de más variables en el modelo, lo cual le permite contar con una cantidad mayor de información. Por su parte, el modelo de ML que se usará es el LSTM (long short term memory), un modelo de deep learning basado en redes neuronales recurrentes. De esta forma, la pregunta a responder en este documento es: Entre el modelo VAR y el modelo LSTM, ¿Qué modelo es más apropiado para predecir series de tiempo de criptomonedas y por qué?

El resto del documento está dividido en cuatro secciones. La primera consiste del marco teórico que abarca, de manera comprimida, la literatura existente respecto de los modelos utilizados, así como de investigaciones acerca de la predicción en el precio de criptomonedas y de comparaciones entre modelos de predicción econométricos y de ML. La segunda sección es la metodología utilizada. La tercera consiste de resultados y su análisis y la última sección abarca las conclusiones del trabajo.

3. Marco teórico

3.1. Predicción en criptomonedas

Las series de tiempo de criptomonedas cuentan con muchas de las características asociadas a las series de tiempo financieras tradicionales. Según explican Catania et al. (2018), las principales características que comparten, y que dificultan su modelamiento son: alta volatilidad que varía en el tiempo, observaciones extremas, y reacción asimétrica del proceso de volatilidad a señales de observaciones pasadas. Sin embargo, los autores también dan cuenta de que modelos econométricos diseñados para trabajar con series volátiles, como los GARCH, y los cuales han dado resultados satisfactorios al ser usados con series financieras tradicionales, presentan un desempeño muy pobre al ser utilizados en series de tiempo de criptomonedas.

Es justamente por lo anterior que muchas de las investigaciones relacionadas a predecir los valores de criptomonedas se centran en modelos econométricos mucho más sofisticados o, principalmente, en modelos de ML. Un ejemplo de lo anterior se encuentra justamente en el citado artículo de Catania et al., donde los autores realizan predicciones sobre la volatilidad de distintas criptomonedas por medio del modelo Score Driven-GHSKT (generalized Hyperbolic Skew Student's t). En cuanto al segundo caso, los modelos de ML se han centrado principalmente en lo que son las redes neuronales, y es posible encontrar distintos ejemplos en los que se modelan estas series por medio de variaciones del modelo LSTM (Lahmiri & Bekiros, 2018; D'Amato et al., 2022; Hitam & Ismail, 2018; Livieris et al., 2020; Livieris et al., 2021)

3.2. Comparación entre modelos econométricos y modelos de ML para series de tiempo

En cuanto a qué metodología es más apropiada para modelar el comportamiento de series de tiempo con alta volatilidad, se encuentra que al momento de seleccionar el modelo econométrico a trabajar, los autores tienden a decantarse por uno de la familia ARIMA o de la familia GARCH (Elsaraiti & Merabet, 2021; Jang & Lee, 2017; McNally et al., 2018; Siami-Namini & Namin, 2018; Rebane, 2018). Igualmente, la gran mayoría de estudios consultados seleccionan alguna variación del modelo LSTM para realizar sus comparaciones, y, particularmente en los casos en los que se utilizó un modelo de la familia ARIMA, se llega a la conclusión de que las predicciones de los modelos de ML son en general más precisos que los modelos econométricos.

Con base en lo anterior, se puede afirmar que efectivamente los modelos basados en redes neuronales son mejores que los modelos econométricos tradicionales de la familia ARIMA para capturar el comportamiento de las series de tiempo financieras. Sin embargo, también existen hoy día distintos estudios que se centran específicamente en tratar este mismo problema para las series de tiempo de criptomonedas (Jang & Lee, 2017; McNally et al., 2018; Rebane et al., 2018). En pocas palabras, y como bien afirman D’Amato et al. (2022), los distintos trabajos que se han encargado de comparar ambas metodologías dan cuenta de la supremacía de los modelos de machine learning sobre los métodos tradicionales para predecir el precio de las criptomonedas. Sin embargo, en la literatura no fue posible encontrar comparaciones entre el modelo VAR y modelos de ML, lo cual es el objetivo de este trabajo.

4. Metodología

De manera general, para dar respuesta a la pregunta de investigación, se realizó un ejercicio de predicción con los modelos LSTM y VAR. Ambos modelos por supuesto se construyeron sobre la misma base de datos, la cual consiste de la serie históricas de precios semanales de cierre de Bitcoin (BTC-USD). Igualmente, solamente para el modelo VAR se utilizó también la serie histórica de Ethereum (ETH-USD)¹, recordando que la ventaja de este modelo sobre otros modelos econométricos tradicionales para series de tiempo es la posibilidad de incluir más de una ecuación simultánea, así como más variables. El periodo de tiempo seleccionado para alimentar el modelo (es decir, la parte de los datos con la que se entrena el modelo LSTM) fue de la semana del 1 de enero de 2018 hasta la semana del 3 de agosto del 2020, periodo en el que el precio fue relativamente estable, es decir, en donde la volatilidad fue baja (teniendo en cuenta el tipo de series con las que se trabaja), salvo por las últimas observaciones, donde ambas criptomonedas tuvieron una subida abrupta de precios (Figura 1). Lo anterior se hizo con el propósito de poner a prueba ambos algoritmos en condiciones difíciles de predicción, ya que, los predicciones se harán para 20 periodos adelante y se compararán con los valores empíricos registrados, que van de la semana del 10 de agosto de 2020 a la semana del 21 de diciembre del mismo año.

¹Los datos se extrajeron de Yahoo Finance.

²Se seleccionaron 5 rezagos, de forma que coincida con los rezagos del modelo VAR, los cuales son elegidos a partir de diferentes criterios de información.

³Los hiperparámetros tenidos en cuenta en el algoritmo LSTM fueron: número de neuronas, función de activación y optimizador. Por otra parte en el modelo VAR fueron: número de rezagos y presencia o no de términos determinísticos, es decir, constante y tendencia.

En lo que respecta al algoritmo LSTM, demanda una estructura de datos en la cual, una vez seleccionada la cantidad de rezagos, se debe crear una tabla donde cada columna represente el precio actual de Bitcoin (p_t) y sus rezagos ($p_{-1}, p_{-2}, p_{-3} \dots$)². Una vez hecho esto, se pueden utilizar estos datos como input del algoritmo, es decir, como la variable x . Por otra parte, el modelo VAR utiliza los datos como una secuencia de valores y hace uso de las dos series de tiempo mencionadas.

El modelo de machine learning, el LSTM, es un modelo de aprendizaje supervisado, y, si bien a priori puede parecer similar al VAR, en el sentido de que ambos modelos utilizan como variable x los distintos rezagos de la variable y (el valor a predecir), ambos cuentan con una lógica distinta. Por un lado, el modelo econométrico VAR realiza una regresión de un vector, compuesto por el valor de las series en el momento t sobre rezagos de ambas variables. Se identifican parámetros para cada uno de los rezagos, los cuales le otorgaran mayor o menor peso en la explicación del valor más reciente de la variable endógena. Por otra parte, el modelo LSTM es un tipo de red neuronal recurrente, lo que significa que se retro-alimenta de sus propios outputs, pero lo que diferencia a este algoritmo es que permite mantener información a lo largo de la secuencia de entrenamiento y no solamente se enfoca en la información en corto plazo.

Para optimizar el desempeño de ambos modelos se optó por modificar los hiperparámetros³. Para el modelo LSTM se utilizó un bucle para probar distintos hiperparámetros y elegir aquella combinación que minimizara el error cuadrático medio (ECM). Por otra parte, para el modelo VAR, los hiperparámetros se eligieron a partir de los criterios de información (AIC, HQ, SC y FPE) y de la significancia estadística de los términos determinísticos. Finalmente, como se mencionó, se realizó la predicción 20 pasos adelante y la forma de comparar la bondad de predicción de ambos modelos fue por medio del ECM, de forma que se pudiera establecer cuál de los dos arroja mejores resultados predictivos.

5. Resultados y análisis

Como se observa en el cuadro 1, el algoritmo LSTM es, de manera general, superior en términos de pre-




Figura 1: This is a wide figure that spans both columns.

dictibilidad, puesto que la métrica de ECM del VAR para la totalidad de las predicciones es casi 10 veces superior⁴. Sin embargo, al observar la Figura 2 no se evidencia tanta diferencia entre las predicciones de ambos modelos para los primeros 10 periodos. Es por ello que también se calculó la el ECM para esos periodos, y se encontró que el modelo VAR presentaba mejores predicciones, al ser su ECM parcial más de 3 veces menor al del modelo LSTM. Lo anterior se debe a que la serie es relativamente estable en las primeras observaciones, y como el VAR realiza predicciones acercándose a la media de los datos, se explica la ventaja con dicho intervalo de tiempo. No obstante, al enfrentarse a cambios bruscos en la serie de tiempo, como se evidencia en la Figura 2, el modelo VAR falla rotundamente en la predicción de los precios. Por otra parte, el algoritmo LSTM se destaca por tener una mejor precisión en el intervalo de mayores cambios en el precio de Bitcoin, es decir, en los último 10 periodos predichos, por lo que se podría afirmar, hasta cierto punto, que es más apto para el modelamiento de series de criptomonedas.

	Total (20)	Parcial(10)
VAR	33852640	170162
LSTM	3394711	611360
Cociente	9,9722	0,2783

Cuadro 1: Comparación de la predictibilidad de los modelos según su ECM, con 20 y 10 pasos adelante

La Figura 2 es muy diciente al exponer las virtudes y falencias de los modelos LSTM y VAR. Se puede ver con claridad la mejor predicción del modelo LSTM,

que como se mencionó, es cerca de 10 veces mejor que la del modelo VAR en predicción general ⁵. Estos resultados a favor del LSTM se pueden deber a que, al ser un modelo guiado por los datos, es capaz de adaptarse mejor a cambios bruscos. Igualmente, el hecho de que presente tan buenas predicciones a largo plazo, es decir, varios periodos adelante, es testimonio de que el algoritmo tampoco es tan dependiente de los valores registrados muchos periodos atrás al momento de realizar predicciones. Por otro lado, los resultados evidenciados en los primeros 10 periodos solamente, en los que el modelo VAR presentó resultados considerablemente mejores a los del LSTM, se deben en parte al hecho de que en estos periodos la serie presentó un comportamiento más estable. Sin embargo, su pobre desempeño en los últimos dos periodos, además de explicarse por la volatilidad presentada, también se debe a que, luego de varios periodos, las predicciones de los modelos VAR tienden a converger hacia la media de la serie, por lo que no son fiables para realizar predicciones a largo plazo.

6. Conclusiones y trabajos futuros

Este trabajo da cuenta una vez más de la complicada tarea que es predecir adecuadamente los valores futuros de series de tiempo tan caóticas como lo son las financieras y las de criptomonedas. Sin embargo, también brinda evidencia de que se mantiene la tendencia presentada en otras investigaciones: los modelos de machine learning son más aptos que los modelos econométricos tradicionales para predecir series

⁴El cociente se calcula realizando la división del ECM del VAR sobre el ECM del LSTM

⁵En el proceso de optimización del algoritmo LSTM según la semilla utilizada y el numero de iteraciones, aumenta o disminuye ligeramente el valor del error, sin embargo se mantienen las conclusiones representadas en los coeficientes Total y Parcial.




Figura 2: This is a wide figure that spans both columns.

de tiempo de criptomonedas, y parecen ser el camino a seguir en este campo. En el problema particular abarcado acá, queda en evidencia que modelos de redes neuronales, como lo es el LSTM, realizan mejores predicciones que el modelo econométrico VAR, el cual, pese a poder contar con más información, como lo fueron en este caso los datos de una serie de tiempo complementaria, sigue sumamente restringido por algunos de los supuestos econométricos clásicos.

En efecto, los mejores resultados obtenidos por el modelo LSTM se deben a que este se adapta de mejor manera a la alta volatilidad característica de este tipo de series de tiempo. No cabe duda de que esto es gracias a que este modelo no cuenta con restricciones similares a las del modelo VAR, sino que es guiado por la naturaleza de los datos con los que trata, sumado a la poca dependencia a la información de periodos anteriores que presenta. Es así como el LSTM logra una mayor precisión general, así como en predicciones de largo plazo. Ahora bien, se establece el matiz de que, en condiciones de estacionariedad claras, se podría preferir el modelo VAR, pero esto es algo que se aleja mucho de los movimientos bursátiles de las criptomonedas. Además, la mejor predicción del modelo VAR en el corto plazo evidenciada en este trabajo no es suficiente para compensar los peores resultados obtenidos en general y a largo plazo.

En futuras investigaciones se podría utilizar más información complementaria, puesto que en este trabajo solo se utilizó la serie de tiempo adicional de Ethereum, y es muy probable que la presencia de más variables derive en predicciones más precisas. Igualmente, equilibrar la información disponible para cada modelo, ya que en este caso el modelo VAR contó con

justamente con los datos de la serie de Ethereum, con los que no contó el modelo LSTM, por lo que un futuro trabajo que utilice un modelo derivado del LSTM podría incluir más información en este y así obtener distintos resultados. Finalmente, replicar lo hecho en este trabajo con otras criptomonedas⁶ y realizar las comparaciones entre modelos con base en otras métricas, de forma que sea posible generalizar las conclusiones aquí encontradas.

7. Bibliografía

- Barlin, R. (2017). Regulation on the rise as bitcoin gains popularity. *The CPA Journal*, 87(6), 10-11.
- Catania, L., Grassi, S., Ravazzolo, F. (2018). Predicting the volatility of cryptocurrency time-series. In *Mathematical and statistical methods for actuarial sciences and finance* (pp. 203-207). Springer, Cham.
- D'Amato, V., Levantesi, S., Piscopo, G. (2022). Deep learning in predicting cryptocurrency volatility. *Physica A: Statistical Mechanics and its Applications*, 596, 127158.
- Elsaraiti, M., Merabet, A. (2021). A comparative analysis of the arima and lstm predictive models and their effectiveness for predicting wind speed. *Energies*, 14(20), 6782.
- Hitam, N. A., Ismail, A. R. (2018). Comparative performance of machine learning algorithms for cryptocurrency forecasting. *Ind. J. Electr. Eng.*

⁶En el código se exploró la existente relación entre Bitcoin y Ethereum por medio del modelo VAR, por lo que se esperaba unos resultados análogos al trabajar predicciones de la segunda criptomoneda

- Comput. Sci, 11(3), 1121-1128.
- Jang, H., Lee, J. (2017). An empirical study on modeling and prediction of bitcoin prices with bayesian neural networks based on blockchain information. *Ieee Access*, 6, 5427-5437.
- Lahmiri, S., Bekiros, S. (2019). Cryptocurrency forecasting with deep learning chaotic neural networks. *Chaos, Solitons Fractals*, 118, 35-40.
- Livieris, I. E., Kiriakidou, N., Stavroyiannis, S., Pintelas, P. (2021). An advanced CNN-LSTM model for cryptocurrency forecasting. *Electronics*, 10(3), 287.
- Livieris, I. E., Pintelas, E., Stavroyiannis, S., Pintelas, P. (2020). Ensemble deep learning models for forecasting cryptocurrency time-series. *Algorithms*, 13(5), 121.
- McNally, S., Roche, J., Caton, S. (2018, March). Predicting the price of bitcoin using machine learning. In *2018 26th euromicro international conference on parallel, distributed and network-based processing (PDP)* (pp. 339-343). IEEE.
- Paiva, F. D., Cardoso, R. T. N., Hanaoka, G. P., Duarte, W. M. (2019). Decision-making for financial trading: A fusion approach of machine learning and portfolio selection. *Expert Systems with Applications*, 115, 635-655.
- Rebane, J. (2018). Seq 2 Seq RNNs and ARIMA models for Cryptocurrency Prediction : A Comparative Study.
- Siarni-Namini, S., Namin, A. S. (2018). Forecasting economics and financial time series: ARIMA vs. LSTM. *arXiv preprint arXiv:1803.06386*.